TITOLO

Analisi SQL: Dati Globali su Paesi, Economia ed Energia

SOTTOTITOLO

Integrazione di dataset socio-economici ed energetici tramite PostgreSQL

AUTORE: FRANCESCO BENASSI

CORSO: PROGETTO FINALE SQL

https://drive.google.com/drive/folders/1Dsgy_pNVW5bE5AN6-okvDm_8_Oul9Wo0?usp=drive_link

OBIETTIVO

Creare un database relazionale integrando due dataset globali per:

- analizzare indicatori socio-economici
- analizzare dati energetici
- individuare correlazioni tra economia, energia e ambiente
- rispondere a domande complesse tramite SQL

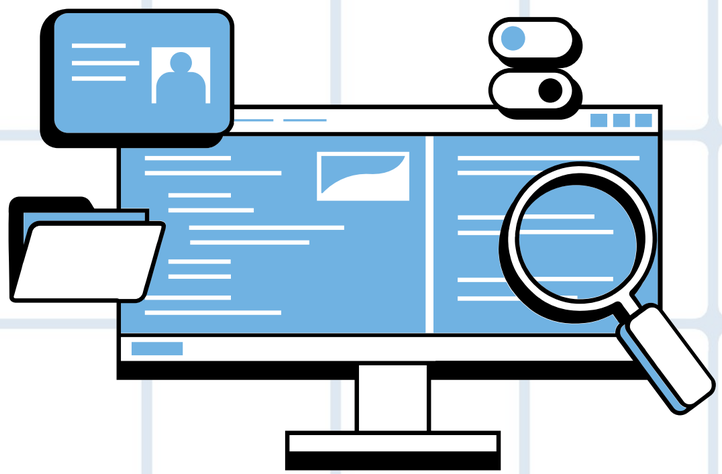


DATASET UTILIZZATI

Global Country Information Dataset

Contiene

- ✓ Popolazione
- ✓ PIL
- ✓ Salute
- ✓ Istruzione
- ✓ Occupazione
- ✓ Geografia



Global Data on Sustainable Energy Dataset

Contiene

- ✓ Rinnovabili
- ✓ Elettricità
- ✓ Emissioni CO_2
- ✓ Energia low-carbon
- ✓ Consumi energetici

FASE 1: ANALISI PRELIMINARE

- studio dei dataset
- esplorazione colonne
- verifica compatibilità dataset
- analisi qualità dei dati
- identificazione campi utili



FASE 2: FORMULAZIONE DELLE DOMANDE

PER GUIDARE L'INTERA ANALISI HO DEFINITO 11 DOMANDE DIVISE IN 3 CATEGORIE

GRUPPO A – Analisi Global Country Information Dataset

A1 – Relazione tra densità demografica e PIL pro capite
A2 – Differenze territoriali del PIL tramite macro-regioni
A3 – Identificazione outlier economici tramite z-score
A4 – Istruzione terziaria e disoccupazione: esiste un pattern?
A5 – Relazione tra area forestale e emissioni pro capite (profilazione ambientale)



GRUPPO B – Analisi Global Data on Sustainable Energy Dataset

B1 – Evoluzione dell'accesso all'elettricità (2000–2020)
B2 – Transizione energetica per fasce di PIL pro capite
B3 – Cambiamento della quota di elettricità low-carbon nel tempo (cluster di transizione)

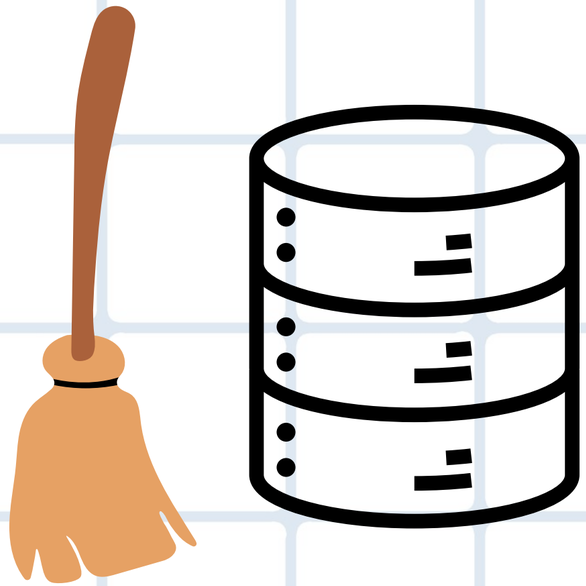


GRUPPO C – Analisi relazionale (integrazione tra dataset)

C1 – Speranza di vita e accesso all'elettricità
C2 – Urbanizzazione, tassazione e impatto crisi 2008 sull'efficienza energetica
C3 – Pressione demografica e stabilità del mix energetico (2000–2020)

FASE 3: PULIZIA DEI DATI

- Importazione dei dataset in Google Sheets.
- Correzione valori mancanti, formati incoerenti e intestazioni.
- Uniformazione dei nomi delle colonne per permettere un'importazione pulita in PostgreSQL.
- Utilizzo strumenti di supporto AI per generare formule e automatizzare la pulizia (come Code Interpreter di ChatGPT).
- Inserimento dei dataset puliti nella cartella presente al link drive chiamata Dataset_clean.



https://drive.google.com/drive/folders/1Dsgy_pNVW5bE5AN6-okvDm_8_Oul9Wo0?usp=drive_link

FASE 4 PARTE 1: MODELLAZIONE DEL DATABASE

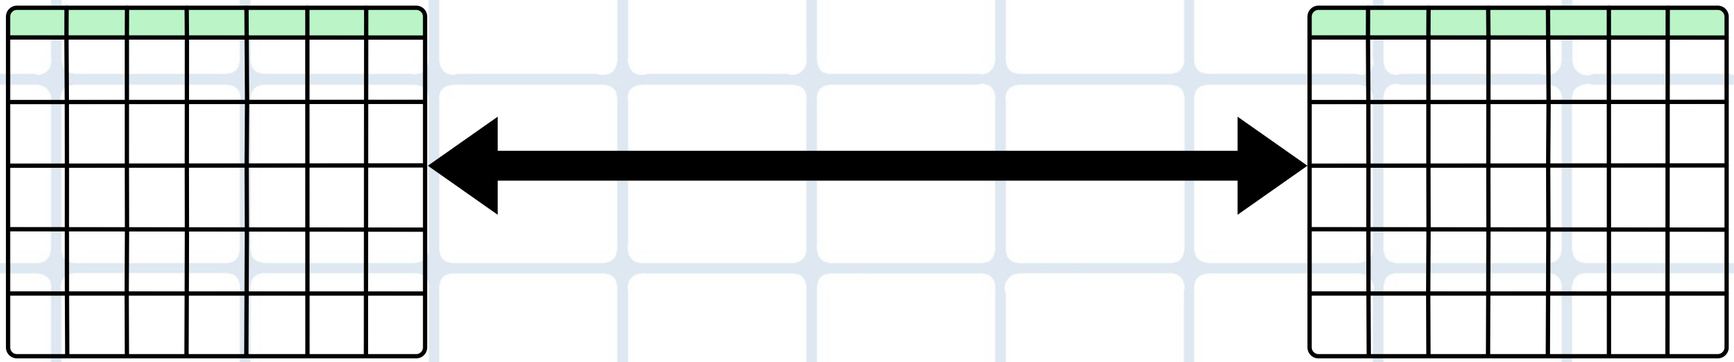
STRUTTURA FINALE

Tabella 1: world_data_2023

- 37 colonne
- PK: id (serial)

Tabella 2: energy_data

- 21 colonne
- FK: country_id
- Relazione: 1 Paese → N anni



FASE 4 PARTE 2: CREAZIONE TABELLE SQL

ESTRATTO

QUERY PER CREARE TABELLA RELATIVA AL GLOBAL COUNTRY INFORMATION DATASET

QUERY SQL

```
CREATE TABLE world_data_2023 (
  Country TEXT,
  GDP NUMERIC,
  Population NUMERIC,
  Life_expectancy NUMERIC,
  ...
);
```

QUERY PER CREARE TABELLA RELATIVA AL GLOBAL DATA ON SUSTAINABLE ENERGY DATASET

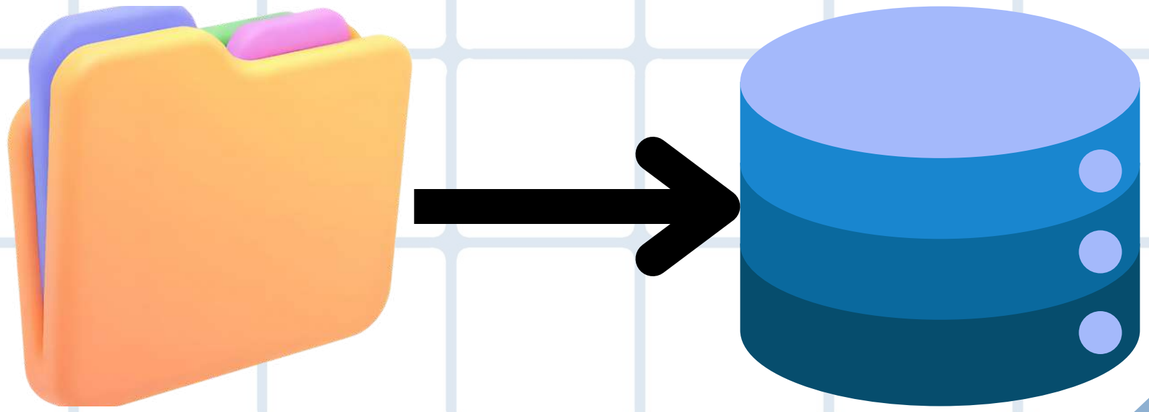
QUERY SQL

```
CREATE TABLE energy_data (
  EntityTEXT,
  Year INT,
  gdp_growth NUMERIC,
  Land_AreaKm2 NUMERIC,
  ...
);
```

FASE 4 PARTE 3: IMPORTAZIONE DATASET

PROCEDURA

1. RIGHT CLICK → IMPORT
2. FORMAT: CSV
3. HEADER: YES
4. DELIMITER: ,
5. ENCODING: UTF8
6. SELEZIONE FILE PULITO



✓ IMPORT COMPLETATO CORRETTAMENTE

✓ NESSUN ERRORE NEI DATI

FASE 4 PARTE 4: COLLEGAMENTO TRA TABELLE

QUERY PER AGGIUNTA PRIMARY KEY ALLA TABELLA WORLD_DATA_2023

QUERY SQL

```
ALTER TABLE world_data_2023
ADD COLUMN id SERIAL PRIMARY KEY;
```

QUERY PER AGGIUNTA FOREIGN KEY ALLA TABELLA ENERGY_DATA

QUERY SQL

```
ALTER TABLE energy_data
ADD COLUMN country_id INT;
```

QUERY PER POPOLAMENTO FOREIGN KEY IN ENERGY_DATA

QUERY SQL

```
UPDATE energy_data
SET country_id = world_data_2023.id
FROM world_data_2023
WHERE Entity = Country;
```

QUERY PER LA CREAZIONE VINCOLO FRA LE DUE TABELLE

QUERY SQL

```
ALTER TABLE energy_data
ADD CONSTRAINT fk_country
FOREIGN KEY (country_id)
REFERENCES world_data_2023(id);
```

FASE 5: QUERY SQL PER ANALISI DATABASE

IN QUESTA FASE HO RISPOSTO AI QUESITI DEFINITI NELLA FASE 2 ATTRAVERSO LA SCRITTURA DI QUERY SQL TRAMITE L'AUSILIO DI PGADMIN4(È L'INTERFACCIA GRAFICA UFFICIALE PER POSTGRESQL CHE PERMETTE DI GESTIRE DATABASE, TABELLE E QUERY IN MODO SEMPLICE)



LE QUERY SONO STATE SUDDIVISE IN 3 GRUPPI

A) SOCIO-ECONOMICHE
B) ENERGETICHE
C) JOIN TRA DATASET

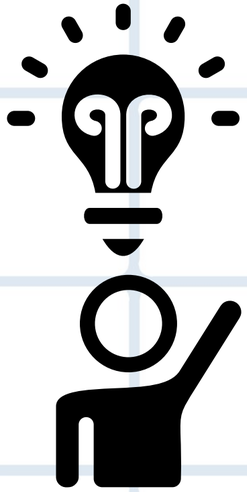


QUI DI SEGUITO IL LINK CHE PORTA DIRETTAMENTE ALLA CARTELLA DRIVE CONDIVISA AL CUI INTERNO VI E' IL FILE README CON TUTTE LE FASI DETTAGLIATE, LA SOTTOCARTELLA DATASET_CLEAN CON I DATASET PULITI, LA SOTTOCARTELLA RISULTATI_QUERY CON GLI SCREENSHOOT DELLE VISUALIZZAZIONI OTTENUTE DALLE QUERY E INFINE IL FILE SCRIPT_SQL CON TUTTE LE QUERY E LE RELATIVE ANALISI APPROFONDITE

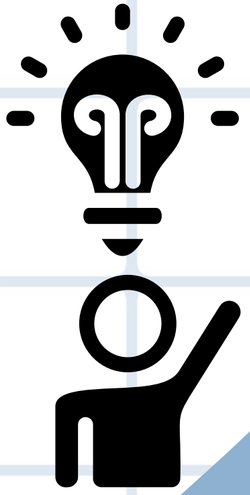
https://drive.google.com/drive/folders/1Dsgy_pNVW5bE5AN6-okvDm_8_Oul9Wo0?usp=drive_link

FASE 6 PARTE 1: INTERPRETAZIONE DEI RISULTATI

GRUPPO A – ANALISI GLOBAL COUNTRY INFORMATION DATASET



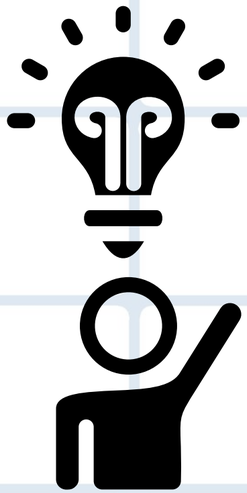
- Le fasce intermedie di densità sono le più ricche; estremi meno performanti.
- Grandi disuguaglianze in Europa e Middle East; Africa più omogenea ma povera.
- Outlier ricchi (Singapore, Qatar…) e poveri (Burundi, Haiti…). Istruzione terziaria non riduce automaticamente la disoccupazione.
- Profili ambientali molto differenziati; "Alta CO_2 – Bassa foresta" è il cluster più critico.



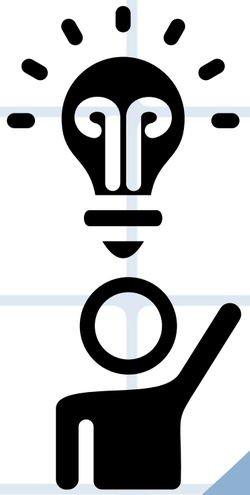
L'analisi piu' approfondita e' presente nel file SCRIPT_SQL nella cartella drive al link sottostante.
https://drive.google.com/drive/folders/1Dsgy_pNVW5bE5AN6-okvDm_8_Oul9Wo0?usp=drive_link

FASE 6 PARTE 2: INTERPRETAZIONE DEI RISULTATI

GRUPPO B – ANALISI GLOBAL DATA ON SUSTAINABLE ENERGY DATASET



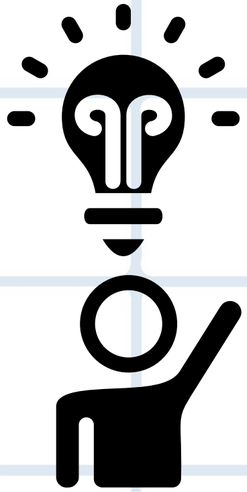
- Accesso elettrico in grande crescita in Asia e Africa, ma restano divari enormi.
- Rinnovabili in forte aumento in Africa; stabilità o calo in regioni ricche (Asia/Oceania/NA).
- Transizione low-carbon polarizzata: metà dei paesi arretra, altri fanno progressi enormi.



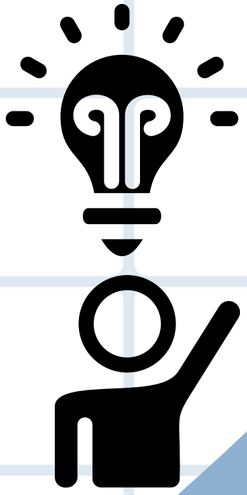
L'analisi piu' approfondita e' presente nel file SCRIPT_SQL nella cartella drive al link sottostante.
https://drive.google.com/drive/folders/1Dsgy_pNVW5bE5AN6-okvDm_8_OuI9Wo0?usp=drive_link

FASE 6 PARTE 3: INTERPRETAZIONE DEI RISULTATI

GRUPPO C – ANALISI RELAZIONALE (INTEGRAZIONE TRA DATASET)



- Speranza di vita alta coincide quasi sempre con accesso elettrico universale.
- Paesi urbanizzati migliorano molto l'efficienza energetica dopo il 2008.
- Maggiore pressione demografica = meno rinnovabili e minore stabilità del mix energetico.



L'analisi piu' approfondita e' presente nel file SCRIPT_SQL nella cartella drive al link sottostante.
https://drive.google.com/drive/folders/1Dsgy_pNVW5bE5AN6-okvDm_8_OuI9Wo0?usp=drive_link

CONCLUSIONI

✓ DATABASE RELAZIONALE COMPLETATO

✓ INTEGRAZIONE DI DUE DATASET COMPLESSI

✓ QUERY DI ANALISI SVILUPPATE

✓ IDENTIFICATE CORRELAZIONI SIGNIFICATIVE

✓ BASE PER ANALISI FUTURI SU ENERGIA E SVILUPPO

GRAZIE PER L'ATTENZIONE

PROGETTO A CURA DI FRANCESCO BENASSI

Link alla cartella drive:
https://drive.google.com/drive/folders/1Dsgy_pNVW5bE5AN6-okvDm_8_Oul9Wo0?usp=drive_link